


REPORT PROJECT DEEP LEARNING

**Klasifikasi Jenis Bencana Alam Berbasis Citra Menggunakan CNN dan Transfer Learning
EfficientNetB0**

Mata Kuliah: Deep Learning Semester Genap 2024/2025



Miryam Almira Levina - 2802465944

Syaqila Najwa Amalia Hambali - 2802488481

Program Studi Ilmu Komputer / Teknik Informatika

Universitas Bina Nusantara

Jakarta, 2026

BAB I

PENDAHULUAN

1.1 Latar Belakang dan Deskripsi Masalah

Indonesia merupakan negara yang rentan terhadap berbagai jenis bencana, seperti gempa bumi, tanah longsor, kebakaran perkotaan, dan banjir. Dalam situasi darurat, identifikasi jenis bencana dari gambar dapat membantu proses pemantauan, pelaporan, dan pengambilan keputusan secara lebih cepat. Jika identifikasi masih dilakukan secara manual, prosesnya dapat menjadi lambat dan tidak efisien, terutama ketika jumlah gambar sangat banyak, misalnya dari kamera lapangan, drone, atau media sosial.

Deep learning dapat digunakan untuk mempelajari pola visual dari citra bencana. Model dapat mengenali ciri seperti reruntuhan bangunan pada gempa, tekstur tanah dan lereng pada longsor, api dan asap pada kebakaran kota, serta genangan air pada bencana banjir. Oleh karena itu, proyek ini membangun model klasifikasi citra untuk membedakan empat kelas bencana: Earthquake, Land_Slide, Urban_Fire, dan Water_Disaster.

1.2 Rumusan Masalah dan Task yang Dilakukan

- Bagaimana membangun model deep learning untuk mengklasifikasikan gambar bencana ke dalam empat kelas?
- Bagaimana karakteristik data berdasarkan jumlah gambar, resolusi, dan komposisi warna?
- Bagaimana perbandingan performa CNN Scratch dan EfficientNetB0 sebagai transfer learning model?
- Model mana yang paling layak digunakan berdasarkan accuracy, F1-score, dan ROC-AUC?

1.3 Tujuan Proyek

- Melakukan exploratory data analysis terhadap dataset citra bencana.
- Membangun baseline CNN Scratch dari nol.
- Membangun model transfer learning EfficientNetB0 dengan tahap feature extraction dan fine-tuning.

- Mengevaluasi kedua model menggunakan classification report, bar chart perbandingan, dan ROC curve.


BAB II

Exploratory Data Analysis (EDA)

2.1 Distribusi Kelas

Dataset terdiri dari 2.345 gambar yang terbagi ke dalam empat kelas. Kelas Water_Disaster memiliki jumlah gambar paling banyak, yaitu 1.035 gambar atau sekitar 44,1% dari seluruh data. Tiga kelas lainnya berada pada rentang yang relatif mirip, yaitu Earthquake 435 gambar, Land_Slide 456 gambar, dan Urban_Fire 419 gambar.

Kelas Bencana	Jumlah Gambar	Persentase
Earthquake	435	18,6%
Land_Slide	456	19,4%
Urban_Fire	419	17,9%
Water_Disaster	1.035	44,1%
Total	2.345	100%




Dari grafik terlihat bahwa dataset tidak sepenuhnya seimbang. Water_Disaster menjadi kelas mayoritas dan berpotensi membuat model lebih sering memprediksi kelas tersebut jika tidak ditangani. Kondisi ini menjadi alasan penggunaan class weighting pada proses training.

2.2 Sebaran Resolusi Gambar

Analisis resolusi menunjukkan bahwa ukuran gambar antar kelas sangat bervariasi. Earthquake relatif dekat dengan target 224 pixel, sedangkan Land_Slide, Urban_Fire, dan


Water_Disaster memiliki variasi lebar dan tinggi yang lebih besar, termasuk beberapa outlier dengan resolusi tinggi. Karena input model harus memiliki ukuran tetap, seluruh gambar perlu di-resize ke ukuran target sebelum masuk ke model



Kelas	Min W	Max W	Avg W	Min H	Max H	Avg H
Earthquake	224	308	228	154	225	220
Land_Slide	177	2048	432	119	882	383
Urban_Fire	163	1280	461	153	880	402
Water_Disaster	1.161	1080	524	120	1350	448

2.3 Komposisi Warna RGB


Rata-rata RGB menunjukkan bahwa setiap kelas memiliki karakteristik warna yang berbeda. Urban_Fire cenderung memiliki nilai blue yang lebih rendah dan visual api/asap yang kuat, sedangkan Water_Disaster memiliki komposisi RGB yang relatif tinggi dan seimbang karena banyak gambar berisi air, langit, dan area terang.



Kelas	Red	Green	Blue	Insight
Earthquake	114,0	110,5	107,8	Warna relatif netral karena banyak reruntuhan, debu dan bangunan
Land_Slide	115,3	115,3	106,6	Dominan tanah, vegetasi, dan area natural sehingga red-green cukup seimbang
Urban_Fire	111,4	96,3	87,9	Blue paling rendah (citra banyak mengandung api, asap gelap, dan kontras kuat)
Water_Disaster	127,6	125,1	117,0	RGB paling tinggi dan seimbang; banyak area air, langit, atau permukaan terang

2.4 Visualisasi Channel Warna

Visualisasi channel red, green, dan blue membantu melihat bagian gambar yang paling kuat pada setiap kanal. Urban_Fire terlihat lebih menonjol pada channel red karena keberadaan api, sementara Water_Disaster masih terlihat cukup jelas pada banyak channel karena warna air dan area sekitar relatif terang.



BAB III

Metodologi

3.1 Data Preparation dan Split Data


Dataset dimuat menggunakan `tf.keras.utils.image_dataset_from_directory` dengan `label_mode='categorical'`, batch size 32, seed 115, dan target image size 224x224. Pembagian awal dilakukan dengan `validation_split=0.2` sehingga 80% data digunakan untuk training dan 20% sisanya dibagi menjadi validation dan testing berdasarkan batch.

Subset	Jumlah File/Batch	Keterangan
Training	1.876 file / 59 batch	Digunakan untuk melatih model
Validation	7 batch / sekitar 224 gambar	Digunakan untuk memantau val_loss dan val_accuracy
Testing	8 batch / 245 gambar	Digunakan untuk evaluasi akhir model

3.2 Preprocessing dan Augmentas

Untuk CNN Scratch, gambar dinormalisasi ke rentang 0 sampai 1 menggunakan `Rescaling(1/255)`. Untuk `EfficientNetB0`, gambar dipertahankan dalam rentang 0 sampai 255 karena `EfficientNetB0` dari Keras sudah memiliki preprocessing internal. Augmentasi hanya diterapkan pada training set agar tidak terjadi data leakage ke validation dan test set.

Model	Preprocessing	Augmentasi
CNN Scratch	Rescaling 1/255	RandomFlip, RandomRotation 0.15, RandomZoom 0.1, RandomContrast 0.1, RandomTranslation 0.1
EfficientNetB0	Cast ke float32 tanpa rescaling manual	RandomFlip horizontal dan vertical, RandomRotation 0.2, RandomZoom 0.15, RandomContrast 0.2, RandomTranslation 0.1, RandomBrightness 0.1



Augmentasi membantu model belajar lebih robust terhadap variasi posisi, orientasi, zoom, dan pencahayaan. Hal ini penting karena gambar bencana biasanya berasal dari sumber yang berbeda dan tidak selalu memiliki komposisi visual yang seragam.

3.3 Class Weighting

Karena dataset memiliki ketidakseimbangan kelas, class weighting digunakan agar model tidak terlalu bias pada kelas mayoritas. Pada notebook, bobot kelas diperoleh melalui Bayesian Optimization berdasarkan F1 Macro pada model proxy. Hasil bobot akhir yang digunakan adalah sebagai berikut.

Kelas	Index	Class Weight
Earthquake	0	2.5000
Land_Slide	1	1.9160
Urban_Fire	2	2.5197
Water_Disaster	3	1.8000

Bobot lebih tinggi diberikan pada kelas yang membutuhkan perhatian lebih selama training. Tujuan utamanya bukan hanya menaikkan accuracy, tetapi menjaga F1 Macro agar performa antar kelas lebih seimbang.

3.4 Model CNN Scratch

CNN Scratch digunakan sebagai baseline karena model ini dilatih dari nol tanpa pengetahuan pretrained. Arsitekturnya terdiri dari beberapa blok Conv2D, aktivasi, MaxPooling2D, GlobalAveragePooling2D, Dense, Dropout, dan output softmax untuk empat kelas. Total parameter model adalah 414.398 parameter atau sekitar 1,58 MB.

Komponen	Konfigurasi
Input	Input layer model didefinisikan sebagai $320 \times 320 \times 3$, sementara pipeline data menyuplai gambar 224×224 . TensorFlow menangani perbedaan ini secara otomatis, namun kondisi ini berkontribusi pada fluktuasi training yang terlihat di grafik
Convolution blocks	Conv2D 32, 64, 128, dan 250 filter dengan MaxPooling2D
Regularisasi	Dropout 0.1 setelah block 3 dan Dropout 0.3 sebelum output
Classifier	GlobalAveragePooling2D -> Dense 128 ReLU -> Dense 4 softmax
Optimizer	AdamW learning rate 0.001
Callback	EarlyStopping monitor val_loss, patience 12, restore_best_weights=True

3.5 Transfer Learning EfficientNetB0

EfficientNetB0 digunakan sebagai transfer learning model dengan bobot pretrained ImageNet. Model ini dipilih karena efisien dan mampu mengekstraksi fitur visual yang lebih kaya dibanding CNN sederhana. Training dilakukan dalam dua tahap: feature extraction dan fine-tuning.

Komponen	Stage 1 - Feature Extraction	Stage 2 - Fine-tuning
Backbone	EfficientNetB0 frozen	Backbone dibuka sebagian; layer sebelum 30 layer terakhir tetap frozen.
Input	$224 \times 224 \times 3$	$224 \times 224 \times 3$
Head	GAP -> BN -> Dense 512 -> Dropout 0.4 -> Dense 256 -> Dropout 0.3 -> Dense 4	Head sama, sebagian backbone ikut dilatih.
Learning Rate	$5e-4$	$1e-5$, lalu dapat turun oleh ReduceLROnPlateau.

Loss	Categorical Crossentropy dengan label smoothing 0.1	Categorical Crossentropy dengan label smoothing 0.1.
Parameter	4.842.919 total, 790.788 trainable	Trainable bertambah karena sebagian backbone dibuka.

BAB IV

Hasil dan Analisis


4.1 Hasil Evaluasi Model CNN Scratch

CNN Scratch mencapai accuracy 0.6857 dan F1 Macro 0.6213 pada test set. Hasil ini cukup baik sebagai baseline, tetapi performanya belum stabil karena model dilatih dari nol pada dataset yang relatif kecil dan memiliki imbalance.


Metrik	Nilai
Accuracy	0.6857
F1 Macro	0.6213
F1 Weighted	0.6603
Support Test	245 gambar

Performa per kelas CNN Scratch:

Kelas	Precision	Recall	F1-Score	Support
Earthquake	0.6889	0.6078	0.6458	51
Land_Slide	0.7857	0.2500	0.6458	44
Urban_Fire	0.9474	0.6571	0.6458	35
Water_Disaster	0.6645	0.8957	0.6458	115
Macro Avg	0.7203	0.6027	0.6213	245
Weighted Avg	0.7024	0.6857	0.6603	245



Pada grafik accuracy, training accuracy meningkat secara perlahan hingga mendekati 0.69. Namun validation accuracy sangat fluktuatif, beberapa kali turun tajam dan kembali naik. Grafik loss juga menunjukkan validation loss yang tidak stabil, bahkan muncul spike tinggi. Pola ini menunjukkan bahwa CNN Scratch belum memiliki generalisasi yang stabil dan sensitif terhadap variasi validation batch.



Confusion matrix CNN Scratch menunjukkan bahwa Water_Disaster paling sering dikenali benar karena jumlah data dan visualnya lebih dominan. Kelemahan utama ada pada Land_Slide: recall hanya 0.2500, artinya banyak gambar Land_Slide masuk ke kelas lain. Hal ini wajar karena citra longsor dapat terlihat mirip dengan reruntuhan atau area tanah pada kelas lain.


4.2 Hasil Evaluasi Model EfficientNetB0 (Transfer Learning)

EfficientNetB0 menunjukkan peningkatan yang jelas dibanding CNN Scratch. Model ini mencapai accuracy 0.8163, F1 Macro 0.7939, dan F1 Weighted 0.8129. Hasil tersebut menunjukkan bahwa fitur pretrained ImageNet membantu model mengenali pola visual bencana dengan lebih baik.

Metrik	Nilai
Accuracy	0.8163
F1 Macro	0.7939
F1 Weighted	0.8129
Support Test	245 gambar

Performa per kelas EfficientNetB0:

Kelas	Precision	Recall	F1-Score	Support
Earthquake	0.7241	0.7778	0.7500	54
Land_Slide	0.7838	0.6042	0.6824	48
Urban_Fire	0.8571	0.8571	0.8571	28
Water_Disaster	0.8607	0.9130	0.8861	115
Macro Avg	0.8064	0.7880	0.7939	245
Weighted Avg	0.8151	0.8163	0.8129	245



Pada stage awal, training accuracy EfficientNetB0 naik cepat karena backbone pretrained sudah memiliki pengetahuan visual dari ImageNet. Validation accuracy berada pada rentang


tinggi, sekitar 0.82 sampai 0.89. Setelah fine-tuning dimulai, training accuracy tetap tinggi, tetapi validation accuracy cenderung menurun. Ini menunjukkan bahwa tahap fine-tuning harus dilakukan hati-hati agar tidak overfit pada training set.

Per kelas, Water_Disaster menjadi kelas terbaik dengan F1-score 0.8861. Urban_Fire juga kuat dengan F1-score 0.8571 karena pola api dan asap cukup khas. Land_Slide masih menjadi kelas yang relatif sulit, tetapi meningkat besar dari F1 0.3793 pada CNN Scratch menjadi 0.6824 pada EfficientNetB0.

4.3 Analisis ROC-AUC

Perbandingan akhir menunjukkan bahwa EfficientNetB0 unggul pada seluruh metrik utama. Accuracy meningkat dari 0.6857 menjadi 0.8163, atau naik sekitar 13,06 percentage points. F1 Macro juga meningkat dari 0.6213 menjadi 0.7939, yang berarti performa antar kelas menjadi lebih seimbang.

Metrik	CNN Scratch	EfficientNetB0	Selisih	Pemenang
Accuracy	0.6857	0.8163	+0.1306	EfficientNetB0
F1 Macro	0.6213	0.7939	+0.1726	EfficientNetB0
F1 Weighted	0.6603	0.8129	+0.1526	EfficientNetB0
ROC-AUC Macro	0.8743	0.9510	+0.0767	EfficientNetB0
OvO Macro AUC	0.8827	0.9507	+0.0680	EfficientNetB0
Model Size	1.58 MB	18.47 MB	EffNet lebih besar	CNN untuk resource rendah





Bar chart memperlihatkan gap yang konsisten. EfficientNetB0 tidak hanya unggul pada accuracy, tetapi juga pada F1 Macro. Hal ini penting karena dataset tidak seimbang; jika hanya accuracy yang naik, belum tentu model adil terhadap kelas minoritas. Kenaikan F1 Macro menunjukkan model transfer learning lebih baik dalam mengenali kelas secara menyeluruh.

4.4 Analisis ROC-AUC

ROC-AUC digunakan untuk melihat kemampuan model memisahkan masing-masing kelas dalam skenario one-vs-rest. Semua nilai AUC berada jauh di atas garis random, sehingga kedua model memiliki kemampuan diskriminatif yang cukup baik. Namun EfficientNetB0 tetap lebih unggul pada seluruh kemampuan diskriminatif yang cukup baik. Namun EfficientNetB0 tetap lebih unggul pada seluruh kelas.

Kelas	AUC CNN Scratch	AUC EfficientNetB0	Delta
Earthquake	0.9000	0.9542	+0.0542
Land_Slide	0.7973	0.8981	+0.1008
Urban_Fire	0.9414	0.9880	+0.0466
Water_Disaster	0.8587	0.9637	+0.1050

Macro Average	0.8743	0.9510	+0.0767
OvO Macro	0.8827	0.9507	+0.0680



Peningkatan terbesar terjadi pada Land_Slide dan Water_Disaster. Land_Slide naik dari AUC 0.7973 ke 0.8981, sedangkan Water_Disaster naik dari 0.8587 ke 0.9637. Ini menunjukkan bahwa representasi visual EfficientNetB0 lebih mampu menangkap perbedaan halus antar kelas bencana.

BAB V

PEMBAHASAN

5.1 Analisis Kelas

- Water_Disaster menjadi kelas terbaik pada EfficientNetB0 dengan F1-score 0.8861. Pola air, banjir, dan area tergenang relatif mudah dipelajari oleh model pretrained.
- Urban_Fire juga kuat dengan F1-score 0.8571 karena api dan asap memiliki karakteristik visual yang khas.
- Land_Slide masih menjadi kelas yang paling menantang, tetapi EfficientNetB0 berhasil meningkatkan F1-score dari 0.3793 menjadi 0.6824.
- Earthquake meningkat dari F1-score 0.6458 menjadi 0.7500, menunjukkan transfer learning membantu mengenali pola kerusakan bangunan dan reruntuhan.

5.2 Trade-off Deployment

EfficientNetB0 memiliki performa terbaik, tetapi ukuran modelnya lebih besar, yaitu sekitar 18,47 MB dibanding CNN Scratch sekitar 1,58 MB. Jika sistem akan dijalankan pada server atau cloud, EfficientNetB0 lebih layak dipilih. Jika deployment dilakukan pada perangkat dengan resource sangat terbatas, CNN Scratch dapat dipertimbangkan karena lebih ringan, meskipun performanya lebih rendah.

BAB VI

Kesimpulan dan Saran

6.1 Kesimpulan

- Dataset terdiri dari 2.345 gambar dengan empat kelas bencana. Data tidak seimbang karena Water_Disaster mendominasi 44,1% dari total data.
- Preprocessing resize ke 224x224 diperlukan karena resolusi gambar sangat bervariasi antar kelas.
- EDA RGB menunjukkan perbedaan warna antar kelas, terutama Urban_Fire yang memiliki karakter warna khas dan Water_Disaster yang memiliki RGB relatif tinggi dan seimbang.
- CNN Scratch menghasilkan accuracy 0.6857 dan F1 Macro 0.6213. Model ini cukup baik sebagai baseline, tetapi validation curve menunjukkan generalisasi yang belum stabil.
- EfficientNetB0 menghasilkan accuracy 0.8163 dan F1 Macro 0.7939. Model ini menjadi model terbaik karena unggul konsisten pada accuracy, F1-score, dan ROC-AUC.
- Berdasarkan hasil akhir, EfficientNetB0 direkomendasikan sebagai model utama untuk klasifikasi citra bencana alam pada proyek ini.

6.2 Saran Pengembangan

- Menambah data pada kelas minoritas dan kelas yang sulit, terutama Land_Slide dan Earthquake.
- Mencoba arsitektur lain seperti EfficientNetB3/B4, ConvNeXt, atau Vision Transformer untuk melihat peningkatan performa.
- Menggunakan augmentasi yang lebih spesifik untuk domain bencana, misalnya variasi blur, pencahayaan ekstrem, atau crop area bencana.
- Menambahkan Grad-CAM atau explainability agar bagian gambar yang diperhatikan model dapat dianalisis secara visual.

BAB VII

Referensi

- Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., ... Zheng, X. (2015). *TensorFlow: Large-scale machine learning on heterogeneous systems*. <https://www.tensorflow.org>
- BINUS University. (2023). *Modul deep learning*. School of Computer Science, Bina Nusantara University.
- BINUS University. (2024). *Computer vision and deep learning course notes*. Department of Computer Science, Bina Nusantara University. Diakses dari portal akademik BINUS.
- Chollet, F. (2021). *Deep learning with Python* (2nd ed.). Manning Publications.
- Douzas, G., & Bacao, F. (2019). Geometric SMOTE a geometrically enhanced drop-in replacement for SMOTE. *Information Sciences*, 501, 118–135. <https://doi.org/10.1016/j.ins.2019.06.007>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. <https://www.deeplearningbook.org>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778.
- Keras Team. (2024). *Keras documentation: Transfer learning & fine-tuning*. https://keras.io/guides/transfer_learning/

- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.
<https://doi.org/10.1038/nature14539>
- Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359. <https://doi.org/10.1109/TKDE.2009.191>
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929–1958.
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*.
<https://arxiv.org/abs/1905.11946>